

I. EINLEITUNG

Motivation

50% weniger Aufwand bei Anwendungsentwicklung mit DB
Ermöglicht neue Anwendungen, die ohne DB zu komplex wären
Ausfaktorisieren der Verwaltung großer Datenmengen
ohne Datenbanken

- Daten in Dateien abgelegt, Zugriffsfunktionalität Teil der Anwendung
- Redundanz (in Daten und Funktionalität)
- Programme oft nicht *atomar* (= Programm wird entweder ganz oder gar nicht ausgeführt) – nur bei nicht fehlerfreien Systemen relevant
- Transaktionen* (= Programm oder Kommandofolge) oft nicht *isoliert* (= keine inkonsistenten Zwischenzustände sichtbar) – nur bei mehreren Transaktionen, aber auch bei fehlerfreien Systemen relevant
- Nebenläufigkeit (*concurrency* – paralleler Zugriff auf dieselben Daten) schwer umsetzbar
- Anwendungsentwicklung abhängig von der physischen Repräsentation der Daten (z.B. Datenspeicherung als Tabelle: Reihenfolge Zeilen/Spalten muss bekannt sein)
- Datenschutz (= kein unbefugter Zugriff) nicht gewährleistet
- Datensicherheit (= kein Datenverlust, insb. bei Defekten) nicht gewährleistet

Relationale Datenbanken

auch RDBMS (*relational database management system*)
 \cong Menge von Tabellen
Relation = Menge von Tupeln = Tabelle

RDBMS – Terminologie

Relationenschema: **Fett** geschrieben
Relation: Weitere Einträge der Tabelle
Tupel: Eine Zeile der Tabelle
Attribut: Spaltenüberschrift
Relationenname: Name der Tabelle
DBS: Datenbanksystem = DBMS + Datenbank(en)
Schlüssel: Attribut, das nicht doppelt vergeben werden darf
Fremdschlüssel: Attribut taucht in anderem Relationenschema als Schlüssel auf
Integritätsbedingungen:

1. **lokal**: Schlüssel in Relationenschema
2. **global**: Fremdschlüssel in Datenbankschema

DB-Schema: = Menge der Relationsschemata + globale Integritätsbedingungen

Sicht (*view*): Häufig vorkommende Datenabfrage, kann mit Sichtnamen als „virtuelle“ Tabelle gespeichert werden

```
create view Cartist as
select NAME, JAHR
from Kuenstler
where LAND == "Kanada"
```

Verwendung wie „normale“ Relation:

```
select * from Cartist where JAHR < 2000
```

Nutzung für Datenschutz: Unterschiedliche Benutzer sehen unterschiedlichen DB-Ausschnitt

RDBMS – Anfrageoperationen

Selektion: Zeilen (Tupel) wählen ($\sigma_{KID=1012}(\text{Titel})$)

Projektion: Spalten (Attribute) wählen ($\pi_{KID, NAME}(\text{Kuenstler})$)

Beispiel komplexer Ausdruck: $\pi_{NAME, ART}(\sigma_{KID=1012}(\text{Titel}))$

Ausgangsrelation:

TITLE ID	NAME	ART	GRÖSSE	KID
102	Neil Young – Heart of Gold	mp3	2.920kb	1012
103	Rammstein – Ich liebe Neil Young	wma	4.234kb	1014
104	Neil Young – Old Man	mp3	3.161kb	1012
105	Neil Young – Four Strong Winds	wma	5.125kb	1012

Ergebnis:

NAME	ART
Neil Young – Heart of Gold	mp3
Neil Young – Old Man	mp3
Neil Young – Four Strong Winds	wma

Weitere Operationen: Verbund (*join*), Vereinigung, Differenz, Durchschnitt, Umbenennung

Operationen beliebig kombinierbar (\sim Query-Algebra)

RDBMS – Andragensoptimierung

Algebraische Ausdrücke äquivalent, Abfrage aber unterschiedlich komplex, z.B.

$\sigma_{\text{Vorname}='Klemens'}(\sigma_{\text{Wohnort}='KA'}(SNUSER))$ vs.
 $\sigma_{\text{Wohnort}='KA'}(\sigma_{\text{Vorname}='Klemens'}(SNUSER))$

RDBMS – Physische Datenunabhängigkeit

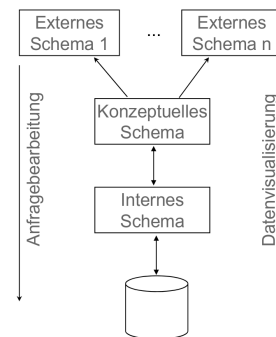
Anfragen deklarativ: Nutzer entscheidet nicht, wie Ergebnis ermittelt wird

Datenunabhängigkeit: DBMS stellt sicher:

1. stabile Anfragenfunktionalität bei physischer Darstellungsänderung
2. Anfrage funktinoiert bei unterschiedlichen Datenbanken (gleiches Schema, unterschiedliche Datenhäufigkeit)

\sim erlaubt höhere Komplexität bei Anwendungsentwicklung

RDBMS – 3-Ebenen-Architektur



Konzeptionelles Schema: Diskursbereich? Welche Entitäten interessant (bei Studierenden Noten interessant, Hobbies usw. nicht)?

Internes Schema: physische Datenrepräsentation

Externe Schemata: Unterschiedlicher Datenausschnitt für unterschiedliche Nutzer (Datenschutz, Übersichtlichkeit, organisatorische Gründe, Verstecken von Änderungen am konzeptionellen Schema)

\sim **Logische Datenunabhängigkeit**

Datenbankprinzipien – Codd'sche Regeln

1. Integration: Einheitliche, nichtredundante Datenverwaltung
2. Operationen: Speichern, Suchen, Ändern
3. Katalog: Zugriff auf Datenbankbeschreibungen im data directory
4. Benutzersichten
5. Integritätssicherung: Korrektheit des DB-Inhalts
6. Datenschutz: Ausschluss unauthorisierter Zugriffe
7. Transaktionen: mehrere DB-Operationen als Funktionseinheit (= Atomarität)
8. Synchronisation: parallele Transaktionen koordinieren (= Isolati-on)
9. Datensicherung: Wiederherstellung von Daten nach Systemfehlern

Strengste bekannte Datenbankdefinition

Funktionale Anforderungen (nichtfunktional z.B.: Wie schnell/zuverlässig muss Dienst sein?)

Prüfungsfragen

1. Was ist eine Sicht?
2. Was ist die relationale Algebra? Wozu braucht man sie?
3. Geben Sie Beispiele für Algebra-Ausdrücke an, die nicht identisch, aber äquivalent sind, an.
4. Was leistet der Anfragenoptimierer einer Datenbank?
5. Erklären Sie: Drei-Ebenen-Architektur, physische/logische Datenunabhängigkeit.

II. CLUSTERING UND AUSREISSER

Räumliche Indexstrukturen – Motivation

Was ist die nächste Bar, die mein bevorzugtes Bier ausschenkt?


Bereichsanfrage: Wie viele Restaurants gibt es im Stadtzentrum?

Ähnlichkeitssuche Bilder: Distanz im Merkmalsraum = Maß der Unähnlichkeit

Index – B+-tree

= non-clustered primary B+-tree

Beispiel: Student(name, age, gpa, major), B+T für gpa (kleiner=links, größer=rechts, (gpa,(x,y)))



Tom, 20, 3.2, EE	Mary, 24, 3, ECE	Lam, 22, 2.8, ME	Chris, 22, 3.9, CS
Chang, 18, 2.5, CS	James, 24, 3.1, ME	Kathy, 18, 3.8, LS	Vera, 17, 3.9, EE
Bob, 21, 3.7, CS	Chad, 28, 2.3, LS	Kane, 19, 3.8, ME	Louis, 32, 4, LS
Pat, 19, 2.8, EE	Leila, 20, 3.5, LS	Martha, 29, 3.8, CS	Shideh, 16, 4, CS

Index – kd-tree

B+T löst Bar-Problem nicht wirklich

kd-tree: Splitting für eine Dimension nach der anderen, dann wieder von vorne

Beispiel: Vier Split-Dimensionen



kd-tree – k-NN

k-NN (= *k-next-neighbour*) := Abstand des *k*-nächsten Nachbarn
Notation: E[k-NN]

Es müssen nur ein paar Rechtecke inspiziert werden, um Resultat zu ermitteln

Implementierung: Priority Queue (Inhalt Datenobjekte/Baumknoten, sortiert nach Abstand zum Anfragepunkt)

Hier: Baum unbalanciert, Balancierung in Realität für mehrdimensionale Daten


Outlier

= Element des Datenbestands, das in bestimmter Hinsicht erheblich vom restlichen Datenbestand abweicht

Mögliche Definition:

Objekt *O*, das in Datenbestand *T* enthalten ist ist ein DB(*p*, *D*)-Outlier, wenn der Abstand von *O* zu mindestens *p* Prozent der Objekte in *T* größer ist als *D*.

Beispiel: *O* ist Outlier, wenn *p* = 0.6, da dann mehr als 60% der Datenobjekte außerhalb des Kreises liegen



Outlier – Algorithmen

Index-basiert: k-NN für jeden Punkt. Stop, sobald $k\text{-NN} < D$

Clustering: Liefert Outlier als Beiprodukt

Abstands basiert

Dichtebasiert

Clustering – Beispiel

Gegeben: Große Kundendatenbank, enthält Eigenschaften und Käufe

Gesucht: Gruppen von Kunden mit ähnlichem Verhalten finden

Clustering – DBSCAN

Dichte: Anzahl Objekte pro Volumeneinheit

Dichtes Objekt: mindestens x andere Objekte in Kugel um Objekt mit Radius ϵ (A)

Dichte-erreichbares Objekt: Objekt in ϵ -Umgebung eines dichten Objekts, das selbst nicht dicht ist (= Clusterrand, B, C)

Rauschen (*Noise*): Objekte, die von keinem dichten Objekt erreicht werden können (N)



DBSCAN – Eigenschaften

Komplexität: Lineare, wenn ϵ -Umgebungen vorberechnet wurden (oder mit räumlichem Index in konstanter Zeit bestimmt werden können)

→ mehrdimensionale Indexstruktur sehr sinnvoll

Rauschen liefert mögliche Outlier

Hochdimensionale Datenräume – Anomalien

Sparsity: Raum ist nur dünn mit Punkten besetzt

Hierarchische Datenstrukturen uneffektiv: bei sehr, sehr vielen Dimensionen ist Abstand zweier Datenobjekte fast gleich dem zweier anderer (unter schwachen Annahmen) → keine echten Outlier (Outlier-Algorithmen liefern mehr oder weniger zufälliges Objekt)

→ nur erfolgsversprechende Teilräume nach Ausreißern absuchen

Interessante Cluster sind i.d.R. nicht Cluster in allen Dimensionen

Outlier – im Höherdimensionalen

Outlier erscheinen als solche nur in Teilräumen

Manche Teilräume ausreißerfrei

Unterschiedlichdimensionale Teilräume enthalten Ausreißer

trivial vs. nichttrivial:

1. **trivial**: Objekt ist in Teilraum bereits Ausreißer
2. **nichttrivial**: Gegenteil

→ Maß für Teilraumrelevanz – wie findet man relevante TR?

Subspace Search

Exponentiell viele Teilräume $P(A)$

Auswahl relevanter Teilräume $RS \subset P(A)$

HiCS – Prinzip

Attribute korrelieren nicht → Outlier in diesem Raum tendenziell eher trivial

Idee: Suche nach Verletzung statistischer Unabhängigkeit (= **Kontrast**)

Prüfungsfragen

1. Warum kann man räumliche Anfragen nicht ohne Weiteres auswerten, wenn man für jede Dimension separat einen B-Baum angelegt hat?
2. Wie funktioniert der Algorithmus für die Suche nach den k nächsten Nachbarn mit Bäumen wie dem kd-Baum?
3. Warum werden bei der NN-Suche nur genau die Knoten inspiziert, deren Zonen die NN-Kugel überlappen?
4. Was ist ein Outlier?
5. Was ist ein Zusammenhang zwischen k -NN-Suche mit Bäumen wie dem kd-Baum und Outlier-Berechnung?
6. Warum ist die Zuordnung Dichte-erreichbarer Punkte mit DBSCAN nichtdeterministisch?
7. Warum sind hierarchische Datenstrukturen in hochdimensionalen Merkmalsräumen für die k -NN-Suche nicht das Mittel der Wahl?
8. Was bedeutet *Subspace Search*?
9. Geben Sie die Unterscheidung zwischen trivialen und nichttrivialen Outliern aus der Vorlesung wieder.
10. Was genau bedeutet *Kontrast* im Kontext von HiCS?

III. DATENBANK-DEFINITIONSSPRACHEN

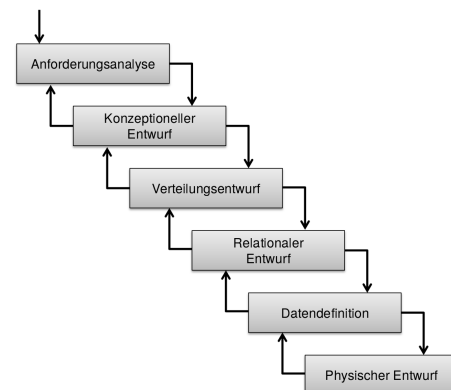
Gewinnung der Konventionen

Beschränkte Anwendungswelt (= Miniwelt, relevanter Weltausschnitt, Diskursbereich)

Daten: Modelle (gedankliche Abstraktionen) der Miniwelt

Datenbasiskonsistenz: Datenbasis ist bedeutungstreu, wenn ihre Elemente Modelle einer gegebenen Miniwelt sind (schärfste Konsistenzforderung)

Datenbankentwurf – Phasenmodell



Datenbankentwurf – Modellierung

Ausschnitt der Wirklichkeit mit Schema beschreiben

Typen = Struktur der Entitäten

Welche Konsistenzbedingungen sind sinnvoll?

Schemakonsistenz: Einhaltung der durch Schema vorgegebenen Konsistenzbedingungen (= von DBMS überprüfbar!)

SQL

= standardisierte Sprache für DB-Zugriff (relational)

Aspekte:

1. Schemadefinition
2. Datenmanipulation (Einfügen, Löschen, Ändern)
3. Anfragen

SQL – SQL-DDL

= SQL data definition language

Teilbereich von SQL, der zu tun hat mit Definition von:

1. Typen
2. Wertebereichen
3. Relationsschemata
4. Integritätsbedingungen

SQL – als Definitionssprache

1. Externe Ebene:

```
{ create | drop } view;
```

2. Konzeptuelle Ebene:

```
{ create | alter | drop } table;
{ create | alter | drop } domain;
```

3. Interne Ebene:

```
{ create | alter | drop } index;
```

Data Dictionary

= Menge von Tabellen und Sichten

Wie Datenbank aufgebaut

Enthält keine Anwendungsdaten, sondern Struktur-Metadaten

SQL – Tabelle anlegen

```
create table Kuenstler
(KID integer, NAME varchar(200),
LAND varchar(50) not null, JAHR integer,
primary key (KID))
```

SQL – Wertebereiche

integer (auch **int**)

smallint

float(p) (auch **float**)

decimal(p,q) (auch **numeric(p,q)**, jeweils mit q Nachkommastellen)

character(n) (auch **char(n)** oder **char** für $n = 1$)

character varying(n) (auch **varchar(n)**, String variabler Länge bis Maximallänge n)

bit(n) (oder **varying(n)** analog für Bitfolgen)

date, **time**, **timestamp**

Wertebereiche – Custom

```
create domain Gebiete varchar(20)
default 'Informatik'
```

```
create table Vorlesungen
(Bezeichnung varchar(80) not null, SWS smallint,
Semester smallint, Studiengang Gebiete)
```

Integritätsbedingungen

Schlüssel kann aus mehreren Attributen bestehen

Fremdschlüssel:

```
create table Titel
(TITLEID integer not null, NAME varchar(200),
KID integer, primary key (TITLEID),
foreign key (KID) references Kuenstler(KID))
```

default-Klausel: Standardwert für Attribut

check-Klausel: weitere lokale Integritätsbedingungen

```
create table Vorlesungen
(Bezeichnung varchar(80) not null, SWS smallint,
Semester smallint, check(Semester between 1 and 9),
Studiengang Gebiete)
```

SQL – alter und drop

```
alter table Lehrstuehle
add Budget decimal(8,2)
```

~~ Änderung Relationsschema im Data Dictionary, existierende Daten werden um **null**-Attribut erweitert

```
drop spaltenname { restrict | cascade }
```


~~ Attribut löschen, falls

1. **restrict**: keine Sichten/Integritätsbedingungen mit diesem Attribut definiert wurden
2. **cascade**: gleichzeitig diese Schichten/Integritätsbedingungen mitgelöscht werden sollen

```
drop table basisrelationenname { restrict | cascade }
```

~~ analog zu Attribut

Speicherhierarchie



Index

Für mehrere Attribute möglich


Index für (gpa, name) \neq Index für (name, gpa)

Index kann nachträglich angelegt bzw. gelöscht werden, ohne Daten selbst zu löschen

Index Bestandteil der physischen Ebene, Index-Definition Teil des internen Schemas

select name from Student where gpa > 4 liefert Ergebnis unabhängig von Existenz eines Index – wenn vorhanden erhebliche Beschleunigung

create unique index typ on auto(hersteller, modell, baujahr) hilft bei Herstellersuche, weniger bei Suche nach Baujahr



Prüfungsfragen

1. Erläutern Sie anhand eines Anwendungsbeispiels, warum man die Menge der zulässigen Zustände einschränken will.
2. Erläutern Sie: Schema-Konsistenz, Datenbasis-Konsistenz.
3. Was ist ein (DB-)Schema?
4. Was ist das Data Dictionary?
5. Warum sollte man sich die Mühe machen, Integritätsbedingungen als Teil des DB-Schemas zu formulieren?
6. Sind Integritätsbedingungen Bestandteil des internen oder des konzeptuellen Schemas? Begründen Sie Ihre Antwort.
7. Wieso sind Indices Bestandteil des internen und nicht des konzeptuellen Schemas?
8. Geben Sie Beispiele für DB-Features an, die zeigen, dass DB-Systeme physische Datenunabhängigkeit nicht vollständig umsetzen.

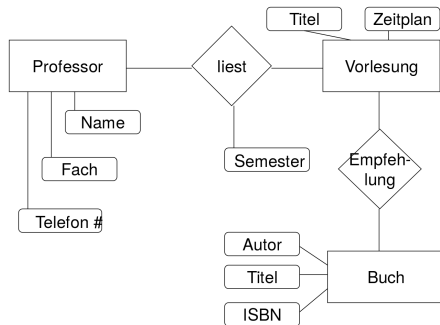
IV. DATENBANKMODELLE FÜR DEN ENTWURF

Entity-Relationship-Modelle

Entity: Objekt der Real-/Vorstellungswelt (z.B. Buch)

Relationship: Beziehung zw. Entities (z.B. Schüler hat Buch)

Attribut: Eigenschaft von Entities (z.B. ISBN)



ER – Modellierungskonzepte

$\mu(D)$: Interpretation von D , mögliche Werte einer Entity-Eig.

$\mu(\text{int})$: Wertebereich \mathbb{Z}

$\mu(\text{string})$: Wertebereich C^* (Folgen von Zeichen aus C)

$\mu(E)$: Menge der möglichen Entities vom Typ E

$\sigma_i(E)$: Menge der *aktuellen* Entities vom Typ E in Zustand σ_i (Index i weglassen, wenn eindeutig)

1. $\sigma(E) \subseteq \mu(E)$
2. $\sigma(E)$ endlich

$\mu(R) = \mu(E_1) \times \dots \times \mu(E_n)$

\rightsquigarrow Die Menge aller möglichen Ehen ist die Menge aller (Mann,Frau)-Paare.

$\sigma(R) \subseteq \sigma(E_1) \times \dots \times \sigma(E_n)$

\rightsquigarrow aktuelle Beziehungen nur zwischen aktuellen Entities


Attribut A eines Entity-Typen E ist im Zustand σ eine Abbildung $\sigma(A) : \sigma(E) \rightarrow \mu(D)$ (nicht $A : \sigma(E) \rightarrow \mu(D)$)

Beziehungsattribute: $\sigma(A) : \sigma(R) \rightarrow \mu(D)$ (Beziehung R , Attribut A , möglicher Wertebereich $\mu(D)$)

Funktionale Beziehungen

Jedem Professor lässt sich ein Zimmer zuordnen, umgekehrt nicht zwingend

Schreibe: $R : E_1 \rightarrow E_2$



Schlüssel


Schlüsselattribute $\{S_1, \dots, S_k\} \subseteq \{A_1, \dots, A_m\}$ für Entity-Typ $E(A_1, \dots, A_m)$

Notation: Schlüssel unterstreichen: $E(\dots, \underline{S_1}, \dots, \underline{S_i}, \dots)$


Schlüssel ist minimal: Wird ein Schlüsselattribut entfernt, so ist das entstehende Tupel nicht mehr eindeutig

Abhängige Entity-Typen


Identifikation: Funktionale Beziehung



IST-Beziehung



Vererbung von Attributen (und Werten):
 $\sigma(\text{Prüfer}) \subseteq \sigma(\text{Mitarbeiter})$




Entwurf – Kardinalitäten

An wv. Beziehungen muss Entity teilnehmen? \rightsquigarrow einschränken


Teilnehmerkardinalität: arbeitet_in(Mitarbeiter $[0, 1]$, Raum $[0, 3]$)

1. jeder Mitarbeiter hat einen zugeordneten Raum, aber einige Mitarbeiter haben kein Arbeitszimmer
2. pro Zimmer arbeiten maximal drei Mitarbeiter
3. ein Zimmer kann leerstehen

Standardkardinalität: 1 Mannschaft steht mit 11 Spielern in Bezug
speziell: m:n/1:n/1:1-Beziehung



Optionale Attribute



Semantische Beziehungen

Spezialisierung: Prüfer Spezialisierung von Mitarbeiter
 \rightsquigarrow Vererbung

Partitionierung: Spezialfall der Spezialisierung, mehrere *disjunkte* Entity-Typen (z.B. Partitionierung von Buch in Monographie und Sammelband)

Generalisierung: Medium ist stets DVD oder Buch
 \rightsquigarrow Abstrakte Klasse Medium

Aggregation: Auto besteht aus Motor, Karosserie,...

\rightsquigarrow Entity aus Instanzen anderer Entity-Typen zusammengesetzt

Sammlung (auch Assoziation): Team ist Gruppe von Person
 \rightsquigarrow Mengenbildung

EER

= Erweitertes ER-Modell

Übernommen: Werte, Entities, Beziehungen, Attribute, Funktionale Beziehungen, Schlüssel


Nicht übernommen: IST-Beziehung – ersetzt durch *Typkonstruktor*

EER – Typkonstruktor


Ersetzt Spezialisierung, Generalisierung, Partitionierung

Eingabetypen mit Dreiecksbasis verbunden (bei Generalisierung spezielle Typen, bei Spezialisierung/Partitionierung allgemeine Typen)


Ausgabetypen mit Spitze verbunden



Spezialisierung



Generalisierung



Mehrfache Spezialisierung

Prüfungsfragen

1. Wie ist die Semantik von Datenmodellen definiert?
2. Geben Sie ein Beispiel für mehrstellige Beziehungen an und erläutern Sie, warum der Sachverhalt mit mehreren zweistelligen Beziehungen nicht korrekt darstellbar wäre.
3. Welche semantischen Beziehungen aus dem EER-Kontext kennen Sie? Erläutern Sie die Unterschiede und geben Sie jeweils ein Beispiel an.

V. RELATIONENENTWURF

Integritätsbedingungen

Schlüssel und Fremdschlüssel einzige Integritätsbedingungen im relationalen Modell

Formalisierung Relationenmodell

Universum U : nichtleere endliche Menge U
 (z.B. $U = \{\text{Name, Alter, Haarfarbe, ...}\}$)

Attribut: $A \in U$

Domäne $D \in \{D_1, \dots, D_m\}$: endliche, nichtleere Menge
 (z.B. $D_1 = \{1, 2, 3, \dots\}$, $D_2 = \{\text{schwarz, rot, blond}\}$)

Attributwert: $\text{dom} : U \rightarrow D$: total definierte Funktion, $\text{dom}(A)$
 Domäne von A , $w \in \text{dom}(A)$ Attributwert für A
 (z.B. $\text{dom}(\text{Haarfarbe}) = \{\text{schwarz, rot, blond}\}$)

Relationenschema: $R \subseteq U$

Tupel (t in $R = \{A_1, \dots, A_n\}$): $t : R \rightarrow \bigcup_{i=1}^n D_i$

Relation (r über $R = \{A_1, \dots, A_n\}$): endliche Menge von Tupeln
 Notation: $r(R)$ (Relation r , Relationenschema R)

r	Name	Alter	Haarfarbe
	Andreas	43	blond
	Gunter	42	blond
	Michael	25	schwarz

Beispiel:

$R = \{\text{Alter, Haarfarbe, Name}\}$

r besteht aus Tupeln t_1, t_2, t_3 ; $t_1(\text{Name}) = \text{"Andreas"}$ usw.

REL: $\text{REL}(R) = \{r \mid r(R)\}$

Menge aller r , die Relation von R sind

(r oben: $r \in \text{REL}(\{\text{Name, Alter, Haarfarbe}\})$,
 aber $r \notin \text{REL}(\{\text{Name, Vorname}\})$)

Datenbankschema: $S = \{R_1, \dots, R_p\}$

Menge von Relationenschemata

Datenbank (über S): Menge von Relationen

$d = \{r_1, \dots, r_p\}$ und $r_i(R_i)$

$d(S)$ Datenbank d über S

Lokale Integritätsbedingung

= Abbildung aller möglichen Relationen zu einem Schema auf true oder false

$b : \{r \mid r(R)\} \rightarrow \{\text{true, false}\} \quad (b \in B)$

Erweitertes Relationenschema: $\mathcal{R} = (R, B)$

Abkürzung:

$r(R)$ – r ist Relation von R

$r(\mathcal{R})$ – r ist Relation von R , und $b(r) = \text{true}$ für alle $b \in B$


SAT: $\text{SAT}_R(B) = \{r \mid r(\mathcal{R})\}$

Menge aller Relationen über erweitertem Relationenschema
 (SAT = *satisfy*)

Prüfungsfragen

1. Wie definieren wir
 - (a) Relation,
 - (b) Relationenschema,
 - (c) Integritätsbedingung?

VI. ABBILDEN - ER ZU RELATIONAL



Abbildungsziel

Kapazitätserhaltende Abbildung: In beiden Fällen gleich viele Instanzen darstellbar

Kapazitätserhöhende Abbildung: relational mehr darstellbar als mit ER

Kapazitätsvermindernde Abbildung: relational weniger darstellbar als mit ER

Abbildungsregeln

Entity-/Beziehungstypen \rightsquigarrow Relationenschemata

Attribute \rightsquigarrow Attribute Relationenschema

Schlüssel \rightsquigarrow übernehmen

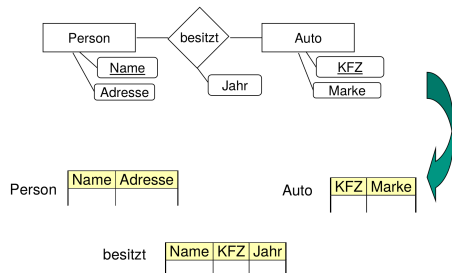
Kardinalitäten \rightsquigarrow Schlüsselwahl

Ggf. Relationenschemata und Entity-/Beziehungstypen verschmelzen

Einführung neuer Fremdschlüsselbedingungen

1. Teil der Schema-Definition
2. Entstehen bei Abbildung von Relationships
3. Ersetzen Linie von Relationship zu Entity

Beziehungstyp \rightsquigarrow Relationenschema mit Attributen des Beziehungstyps und Primärschlüssel der beteiligten Entity-Typen



Prüfungsfragen

1. Warum gibt es im ER-Modell keine Fremdschlüssel?
2. Was bedeutet "kapazitätserhaltende Abbildung"? Geben Sie Beispiele.
3. Wiedergabe der unterschiedlichen Beziehungsabbildungen (1:1, 1:n, m:n)
4. In welchen Fällen lässt sich das Schema optimieren? Was bedeutet Optimierung hier?
5. Wie lassen sich mengenwertige Attribute abbilden?
6. Warum ist Abbildung der folgenden Konstrukte vom ER-Modell ins Relationenmodell problematisch? Rekursive Beziehungen, Partitionierung, Generalis.

VII. RELATIONALER DATENBANKENTWURF

Universalrelation

Universalrelation (von R_1, \dots, R_n): $R = R_1 \bowtie \dots \bowtie R_n$

Universalschlüssel: Schlüssel der Universalrelation

Beispiel: R_1, R_2, R_3 :

PANr	PLZ	PLZ	Ort	Ort	Bundesland

$R_1 \bowtie R_2 \bowtie R_3$:

PANr	PLZ	Ort	Bundesland

Funktionale Relation

In Relation $R(X, Y)$ ist Y von X funktional abhängig (schreibe $X \rightarrow Y$), falls zu jedem X -Wert genau ein Y -Wert gehört (z.B. Buchtitel, ISBN-Nummer oder Stadt, Bundesland)

\rightsquigarrow "X bestimmt Y"

F : Menge von FDs (*functional dependencies*), $f \in F$ einzelne FD

F impliziert f : $F \models f$

Hülle: $F_R^+ = \{f \mid (f \text{ FD über } R) \wedge F \models f\}$

Transitiv: $PLZ \rightarrow Ort \rightarrow Bundesland$

$\rightsquigarrow PLZ \rightarrow Bundesland$

Projektiv: $ISBN \rightarrow Autor \text{ Verlag}$

$\rightsquigarrow ISBN \rightarrow Autor$

Akkumulativ: $ISBN \rightarrow Verlag \text{ Autor, Autor} \rightarrow Straße \text{ Ort}$

$\rightsquigarrow ISBN \rightarrow Verlag \text{ Autor Straße}$

Äquivalente FD-Mengen (Überdeckungen): $F \equiv G$ falls $F^+ = G^+$

Anomalien

VNr	Bez	PANr	Name	Büro
123	Datenbanksysteme	321	Böhm	367
456	Datenhaltung in der Cloud	321	Böhm	367
789	Workflow-Management	432	Mülle	370

Updateanomalie: Büro von Böhm ändert sich

\rightsquigarrow Änderung mehrerer Einträge

\rightsquigarrow Aufwendig, fehleranfällig. Wie vermeiden?

Einfügeanomalie: Neuer Dozent ohne VL (NULL-Werte)

\rightsquigarrow Was wenn VNr Schlüssel?

Löschanomalie: Mülle hält Workflow nicht mehr

\rightsquigarrow Tupel löschen \rightsquigarrow Müsselformation verloren

Abhängigkeitstreue

Beispiel: (InvNr, Titel, ISBN, Autor)

oder (InvNr, Titel, ISBN), (ISBN, Autor)

oder (InvNr, Titel, ISBN), (ISBN, Autor)?

Abhängigkeitstreue: Alle gegebenen Abhängigkeiten sind durch Schlüssel repräsentiert

Verbundtreue

Originalrelationen können durch Verbund der Basisrelationen wiedergewonnen werden

Entwurfsziel

Relationenschemata, (Fremd-)Schlüssel so wählen, dass

1. alle Anwendungsdaten aus Basisrelation hergeleitet werden können (*Verbundtreue*)
2. nur semantisch sinnvolle und konsistente Anwendungsdaten dargestellt werden können (*Abhängigkeitstreue*)
3. möglichst nicht-redundante Daten

Erste Normalform

Nur atomare Attribute in Relationenschemata

Zweite Normalform

Volle FD: β ist voll funktional abhängig von α , wenn aus α kein Attribut entfernt werden kann, so dass FD immer noch gilt.

Gegenbeispiel: PLZ, Bundesland \rightarrow Ort

Partielle FD: liegt vor, wenn ein Nicht-Primattribut voll funktional von einem Teil eines Schlüsselkandidaten abhängt

Zweite NF: keine partiellen Abhängigkeiten
 \rightsquigarrow Durch Struktur der Abhängigkeiten Redundanzen entdecken

Dritte Normalform

Transitive Abhängigkeit: Schlüssel K bestimmt Attributmenge X funktional, ist selber aber auch Attributmenge Y
 \rightsquigarrow transitive Abhängigkeit $\rightarrow X \rightarrow Y$

dritte NF: Keine transitiven Abhängigkeiten zwischen einem möglichen Schlüssel und weiteren nicht-Primattributen

Erreichen durch Elimination von Y und Kopie von X

3NF impliziert 2NF, da partielle Abhängigkeit Spezialfall von transitiver Abhängigkeit

Boyce-Codd-Normalform

Relationenschema \mathcal{R} mit FDs F ist in BCNF, wenn für jede FD $\alpha \rightarrow \beta$ eine der folgenden Bedingungen gilt:

1. $\beta \subseteq \alpha$ (triviale Abhängigkeit)
2. α Schlüssel von \mathcal{R} (oder Obermenge eines Schlüssels von \mathcal{R})

liefert Zerlegung von \mathcal{R}_i in $\mathcal{R}_{i1} = (\alpha \cup \beta)$, $\mathcal{R}_{i2} = \mathcal{R}_i - (\alpha \cup \beta)$
 $(F \ni f : \alpha \rightarrow \beta, \beta \text{ maximal})$

Minimalität

Ziel: Kriterien mit möglichst wenigen Relationenschemata erreichen

Dekomposition

Prinzip: Immer wenn $X \rightarrow Y \rightarrow Z$ wird Relation zerlegt erreicht nur 3NF und Verbundtreue

Normalisierung: Falls $K \rightarrow X \rightarrow Y$, dann Y aus R entfernen und mit X in neues Relationenschema stecken

Beispiel: $U = \{\text{PANr, PLZ, Ort, Land, Staat}\}$,
 $F = \{\text{PANr} \rightarrow \text{PLZ}, \text{PLZ} \rightarrow \text{Ort}, \text{Ort} \rightarrow \text{Land}, \text{Land} \rightarrow \text{Staat}\}$
 $\rightsquigarrow (U, K(F)) = (\{\text{PANr, PLZ, Ort, Land, Staat}\}, \{\{\text{PANr}\}\})$
 Betrachte $\text{PANr} \rightarrow \text{Land} \rightarrow \text{Staat}$. Neue Relationen:

1. $R_1 = \{\text{Land, Staat}\}$
2. $R_2 = \{\text{PANr, PLZ, Ort, Land}\}$

Wiederholen mit R_2

Vorteile: 3NF, Verbundtreue

Nachteile: Keine Abhängigkeitstreue, keine Minimalität, reihenfolgeabhängig, NP-vollständig (Schlüsselsuche)

Syntheseverfahren

Prinzip: Synthese formt Original-FD-Menge F in Menge von Schlüsselabhängigkeiten G so um, dass $F \equiv G$

Abhängigkeitstreue integriert

3NF und Minimalität werden reihenfolgeunabhängig erreicht

polynomielle Zeitkomplexität

Übersicht:

1. Redundanzen eliminieren:
Entfernen unnötiger FDs und Attribute (f überflüssig wenn $F \equiv F - \{f\}$, überflüssige Attribute später)
2. FDs zu Äquivalenzklassen zusammenfassen:
FDs in selber Klasse, wenn sie äquivalente linke Seiten haben \rightsquigarrow ein Relationenschema pro Äquivalenzklasse

Beispiel: $F = \{A \rightarrow B, AB \rightarrow C, A \rightarrow C, B \rightarrow A, C \rightarrow E\}$

1. Redundante FDs: $A \rightarrow C$
Stand: $F' = \{A \rightarrow B, AB \rightarrow C, B \rightarrow A, C \rightarrow E\}$
2. Überflüssige Attribute: B in $AB \rightarrow C$
Stand: $F'' = \{A \rightarrow B, A \rightarrow C, B \rightarrow A, C \rightarrow E\}$
 $\underbrace{\hspace{10em}}_{\text{Äquivalenzklasse}}$
3. Ergebnis Relationenschema:
 $(ABC, \{\{A\}, \{B\}\}), (CE, \{\{C\}\})$

Mehrwertige Abhängigkeiten

Mehrwertige Abhängigkeit (*multi value dependency, MVD*):

Jeder Wert des abhängigen Attributes kommt in Kombination mit allen Werten der anderen Attribute vor

Redundanzbehaftet

Beispiel:

Kurs	Buch	Dozent
AHA	Silberschatz	John D
AHA	Nederpelt	John D
AHA	Silberschatz	William M
AHA	Nederpelt	William M

Neues Buch: für jeden Dozenten anlegen \rightsquigarrow MVD

Vierte Normalform

Beispiel: Relation mit Attributen *Name, Neffe, Hobby*

Es gelte MVD: $\text{Name} \twoheadrightarrow \text{Neffe}$

Wenn

(Heinrich, Martin, Autos) und (Heinrich, Thomas, Basteln)

$\in r$, dann auch

(Heinrich, Martin, Basteln) und (Heinrich, Thomas, Autos)

Formal: r genügt MVD $X \twoheadrightarrow Y \Leftrightarrow$

$\forall t_1, t_2 \in r : [(t_1 \neq t_2 \wedge t_1(X) = t_2(X))$

$\Rightarrow \exists t_3 \in r : t_3(X) = t_1(X) \wedge t_3(Y) = t_1(Y) \wedge t_3(Z) = t_2(Z)]$

4NF: solche MVDs aufspalten

Trivial, wenn keine weiteren Attribute im zugehörigen Schema

Prüfungsfragen

1. Erläutern Sie die folgenden Begriffe: Redundanz, Funktionale Abhängigkeit, Normalform, Verbundtreue, Abhängigkeitstreue, Minimalität.
2. Erläutern Sie die Aussage: "Funktionale Abhängigkeiten beinhalten semantische Informationen."
3. Welche Anomalien kennen Sie? Erläutern Sie für jede dieser Anomalien, warum Sie störend ist.
4. Warum braucht man für Verbundtreue Kriterien, für Abhängigkeitstreue jedoch scheinbar nicht?
5. Welche Normalformen kennen Sie? Sagen Sie umgangssprachlich, wie sie definiert sind.

VIII. RELATIONALE DATENBANKSPRACHEN

Aggregatfunktionen

Prinzip: Berechnung eines Werts aus Werten eines Attributs

Join (natural): Kartesisches Produkt zweier Relationen

Weitere in Standard SQL: count(), sum(), min(), max(), avg()

SQL-Kern

select

Projektionsliste,
arithmetische Operationen und Aggregatfunktionen

from

zu verwendende Relationen, ggf. Umbenennungen

where

Selektions- und Verbundbedingungen
geschachtelte Anfragen (wieder SFW-Block)

group by

Gruppierung für Aggregatfunktionen

having

Selektionsbedingungen an Gruppen